



*Smart Data and Signal Processing Laboratory
of Xiamen University*

CNCC2014 大数据高峰论坛总结

庄培显

2014.10.27

► 百度大数据引擎与大数据预测实践 [沈志勇博士 (Bayesian 出身) 百度研究院大数据实验室]

1. 百度大数据引擎

第三级平台：百度大脑（深度学习，超大规模机器学习，...）



大数据智能分析：从百度到行业




2. 大数据预测应用案例

1) 百度旅游预测

影响因素：往年历史数据统计（整体水平，趋势性，季节性，...），辅助因素（节假日，天气，大事件（世博会）等）

预测模型：



2) 世界杯预测

方法集:

多源数据融合（赔率，历史战绩等）

基于统计量
监督学习
群体智慧
专家融合

复杂模型 { 隐因子模型
层次贝叶斯模型
图上排序模型


攻防因子模型

单场预测结果：
◆ 小组赛（48场）正确率：58.3%
◆ 淘汰赛（15场）正确率：100%
◆ 优于Google和Microsoft等预测

	1/4决赛准确率	1/8决赛准确率	小组赛准确率
Baidu 百度	100%	100%	58.33%
Microsoft	100%	100%	56.25%
Goldman Sachs	100%	100%	37.5%
Google	75%	100%	/



总结：采金子 vs. 数据科学



3. 挑战和问题

- ◆ 信息化→**数据化**→智能化 （数据化程度低）
- ◆ **数据隐私**（一大阻力）
- ◆ 机器学习方法的可复用性低
- ◆ 领域学习成本高




► 互联网时代的大数据 [张潼 百度研究院大数据实验室]

1. 背景

互联网大数据： 网页数据，用户行为记录，地图，语音和图像等；

联系人和服务： 联系人和信息，人和商品，人和人；

大数据应用： 用户体验，广告推荐系统，企业决策等；



2. 大数据智能技术发展（大规模机器学习和深度机器学习）

智能技术发展历史：

- 1) 人工规则 + 工程；
- 2) 数据驱动 + 小规模机器学习（模型从简单到复杂）
- 3) 大数据 + 大规模机器学习（模型从简单到复杂）

互联网公司（百度）现状：

- 1) 大规模： 数据多，参数多，计算多级并行；
- 2) 复杂模型： 非参数，统一参数优化，自动特征学习，自动挖掘隐性概念；

机器学习发展


- 1) 模型： 从简单到复杂，小模型到大模型；
- 2) 计算能力： 从小数据到大数据
- 3) 发展： 大规模机器学习（广告点击行为预测举例），复杂模型，多数据融合；

新一代机器学习技术：大规模+复杂模型+实时更新



Smart Data and Signal Processing Laboratory of Xiamen University


机器学习复杂模型:深度学习



不含隐层的浅层学习模型

浅层网络

人工特征抽取
学习线性组合





含多个隐层的深度学习模型

深层网络

从原始特征出发
自动学习高级特征组合



深度学习发现高级特征：接近人脑



图像识别[百度]



◆ 深度学习成功条件

1. 2010-至今，深度学习在工业界取得巨大成功
2. 手段：**大数据+计算能力+复杂模型+高效算法**

◆ 大数据智能技术展望

1. 目标：计算机智能系统，人工智能；
2. 核心技术：规模和超越人脑的复杂机器学习模型；大规模机器学习能力；
3. 手段：大数据，复杂模型，计算能力和算法，系统合成；



大数据创新应用

Baidu BDL



Smart Data and Signal Processing Laboratory of Xiamen University

3. 大数据行业创新

- ◆ 治疗癌症尝试 （基于海量电子病历癌症智能分析系统）
- ◆ 影视行业 （NETFLIX）
- ◆ 警务 （PREDPOL: 基于海量历史犯罪记录预测犯罪）
- ◆ 旅游预测 （景点拥挤度预测）
- ◆ 互联网金融 （百发指数预测）

百度深度研究院网址：<http://idl.baidu.com/>




大数据展望



创新应用促进行业升级


智能技术大幅度提升

数据爆发式增长



Smart Data and Signal Processing Laboratory of Xiamen University

► 社交网络大数据建模的框架探索 [岳亚丁博士 腾讯公司社交网络运营部数据中心]



► 腾讯社交网络的研究内容

1. 目的：帮助用户高效地社交，并支持人、信息和实物之间的高效流动。

2. 基础研究：

用户的基本属性与行为特征（年龄，兴趣，常去地方，IP所在城市等）

用户和群组的关系结构及其属性（关系链性质，实体圈划分，**Location-based Social Network, LBSN**）

社会化影响和传播（群体趋同性，信息、行为与兴趣的影响和传播，**推断群体主题**）

3. 应用：

社交网络（好友推荐，平台安全）

公司内 （广告业务，个性化推荐，各类分析与预测等）

其他 （国民经济水平评估监测，股市或疾病爆发预测等）



► 恶意行为识别


某些行为容易伪造，社会关系和沟通不易伪造；

例如：某类恶意用户的特征：

- ◆ 较低的局部聚类系数
- ◆ 与“好友”的消息很少
- ◆ 快速频繁的登录

► 公益应用：汶川地震，优先到哪里救人？

根据下线用户数和重新上线用户数，判断局部受损程度。



► 问题和解决思路

1. 问题一：建模过程

- ◆ 辛辛苦苦建立的复杂模型，有时候打不过简单经验规则？
- ◆ 如何“招安”经验规则？
- ◆ 如何构造更多有用的特征？
- ◆ 对同一问题，模型种类很多。每个都要去试？还是跟着别人呢？

建模过程（机器学习）

特征构造：降维（PCA，LPP，ICA，MDS，Kernel PCA，...），构造（DL，Decision tree related AR-related，GP-related，ILP-based，Annotation-based）

模型选择：自组织建模（GMDH，SOM，...），Evolutionary(NEAT,GNARL,...)

规则式模型：DT，AR，PRISM，FoIL，RIPPER,SLPPER, Fuzzy Rules + DST,...



2. 问题二：模型应用

- ◆ 上线测试效果有时候不如离线测试效果？
- ◆ 业务部门不能全盘接受模型结果，而是增加自己的策略？

理由：1) 考虑合作伙伴的关系；

2) 考虑当前推广重点的特定产品（最新app尽快占领市场）

在线学习模型： Hoeffding Tree, VFDT, CVFDT and its variants, UFFT,...;
FIRM, FIRT-DD, SAIRT,...;
REA, LEARN++.NSE, LEARN++.SMOTE, LEARN++.NIF

模型中添加业务测量变量

3. 问题三：推荐系统

- 1) 模型僵硬 2) 个性化不足 3) 退化成搜索 4) 缺少互动



交互式推荐（例如推荐餐馆）

基础假设：系统对用户当前兴趣的把握程度。（实时表达或选择 > 最近发生的准实时行为 > 历史行为）

特点： 1) 模拟现实生活中的推荐过程；

2) 多次交互，逐步逼近用户当前的真正兴趣，缩小候选集范围；

3) 回归到推荐本质！

4. 问题四：SNS的长期演化

◆ QQ会不会成为第二个MySpace、Friendster 轰然倒下？

◆ 产品UI、结构I、功能，对用户行为及市场的影响？

系统全局性指标

产品运营的支持性模型（优化方法）



► 未来模型狂想

探索途径： Heuristics + Principled Approaches

Well-conceived postulation of local mechanisms

Univereal approximator / solver

真正智能： 非目前流行的Intelligent Personal Assistant(Google,Microsoft,Apple..)

基于更少用户反馈、更大数据集背景的推理机制

厦门大学林琛：面向微信公众平台的智能生活服务推荐（CCF腾讯犀牛鸟科研基金获奖项目）



Smart Data and Signal Processing Laboratory of Xiamen University

► 大数据机器学习与数据分析统一编程模型与平台（并行化计算，**Hadoop与Spark**平台）[黄宜华教授 **南京大学PASA大数据实验室**]

网址：<http://pasa-bigdata.nju.edu.cn/>（“**大章鱼**”项目，面向大数据的跨平台统一编程模型、框架和系统平台）


目前两大主流技术与平台：

1. 2007年 **Hadoop** 推出并成为广泛使用的大数据处理技术与平台
2. 2013年 **Spark** 以内存计算大幅度提升大数据处理性能

R 语言：为应用领域分析师熟悉使用的数据分析，统计计算及制图的开源软件系统，提供成千上万的专业模块和实用工具。



► 网络舆情大数据分析应用与产业发展 [李崇刚, 13801228643]




举例说明：

1. 红牛品牌危机
2. 厄瓜多尔总统选举预测

正在做事情：

1. 舆情360应对能力评估
2. 创办星环科技公司
3. 筹备网络舆情服务联盟

(统一标准，共享数据和创新研究)



► 深度学习理论-应用-系统

[窦勇 国防科大并行与分布处理国防科技重点实验室; yongdou@nudt.edu.cn]

网址 : <http://www.china-odl.org:81/login!login.action>

1. 刘鹏 , 中科院 , 遥感图像重构 ;

网址 :

http://sourcedb.radi.cas.cn/zw/zjrck/fyjj/201410/t20141021_4227243.html

2. 王建勇 , 四川大学 , 大数据的时序属性

3. 陈云霁 , 中科院 , 神经网络计算机



► 信息安全论坛

1. 方滨兴院士[从网络主权角度谈自主根域名体系]
2. 胡传平博士 [网络空间虚拟身份管理 **eID**]
3. 杜跃进[网络安全的若干误区]
4. 谭晓生[安全，不至于边界--云计算与物联网时代的安全感]



► 数据开放与隐私论坛

1. 孟小峰 [人大]
2. 曹政 [海外创业]
3. 林东岱 [山大]



Thank you !



Smart Data and Signal Processing Laboratory of Xiamen University